

SUMMARY

시장에서는 MLA 계열의 서비스 운영과 CXL 계열의 제품 기반이 확인된다. 도메인에서는 MLA의 KV 절감만 정량화되며, 두 기술의 코딩 에이전트 응답성·비용은 근거 부족으로 판정을 유보했다. [S1] [S2] [S5] [S6]

1. 분석 배경

긴 코딩 에이전트 세션은 KV cache의 저장·읽기 부담을 키운다.

자기회귀 생성은 이전 토큰의 Key와 Value를 보관해 반복 계산을 줄인다. 코드·대화·도구 출력이 누적될수록 이 캐시가 커지므로, 세션당 캐시를 줄이는 MLA와 외부 메모리 수용량을 늘리는 CXL-PNM을 비교한다. [S1] [S2]

비교 관점	DeepSeek-V2 MLA	CXL-PNM
병목 대응	KV 표현을 저차원으로 압축	KV 수용량 확장·근접 연산
변경 대상	모델 구조·서빙 커널	메모리 계층·서빙 경로

평가 기준일 2026-09-23 · 대상 AI 코딩·업무 에이전트 · 시장성/도메인 2개 관점

2. 기술 선정과 개요

서로 다른 변경 지점을 대표하는 두 기술을 사람이 고정 선정했다.

Human 기반 고정 선정

선정 기준은 접근의 대표성, 요구 전제의 대조성, 두 관점의 자료 확보 가능성이다. 기술 조합을 고정해 실행 간 비교 가능성을 유지한다.

비교축	DeepSeek-V2 MLA	CXL-PNM
핵심 접근	KV를 저차원 잠재공간으로 압축	CXL 메모리에 수용하고 근접 연산
요구 전제	MLA 모델·대응 서빙 커널	CXL-PNM 장치·드라이버·런타임
평가 초점	세션당 KV 예산	외부 KV 수용·선택 연산

2.1 SW: DeepSeek-V2 MLA

모델의 어텐션 구조를 바꾸는 방식이다. 기존 GPU에서 실행할 수 있지만 MLA 모델과 대응 커널이 필요해 임의 모델에 설정만으로 적용할 수 없다. [S1] [S3]

2.2 HW: 1M-Token LLM Inference의 CXL-PNM

CXL 메모리의 PNM 가속기로 KV 관련 선택·연산을 옮긴다. 선정 논문은 PNM-KV와 GPU 병행 방식 PnG-KV를 평가한다. PIM/CXL은 포괄 명칭이며 논문의 구체 방식은 PNM이다. [S2]

평가 단위

도메인 수치는 선정 논문 단위, 시장은 기술 계열까지 조사한다. CXL 제품·규격은 선정 PNM 구현의 상용 운영 증거로 간주하지 않는다. [S2] [S6] [S7]

3. 평가 방법

시장성과 AI 코딩·업무 에이전트 적용성만 평가하며, 근거 부족은 숫자로 메우지 않는다.

시장성: 성장·채택·생태계

기준	판정 방식	해석상 주의
M1 성장성	수요·채택 확대·공급 투자 각 0~2점; 합계 0~1 낮음, 2~3 보통, 4~5 높음, 6 매우 높음	3년 전망의 정성 평가이며 성장률 예측이 아님
M2 채택	주체가 확인된 최고 단계: L4 운영, L3 제품, L2 PoC, L1 연구, L0 미확인	선정 기술과 기술 계열을 분리
M3 생태계	프레임워크·제품·표준·제3자 도구의 Y 수: 3~4 L3, 1~2 L2, 원저자 구현만 L1, 모두 없으면 L0	Y는 원문 체크로 확인; N은 부존재가 아닌 미확인

도메인: 수용성·응답성

기준	판정 방식	해석상 주의
D1 장기 세션	동일 조건 KV 예산·최대 문맥의 증가 배수: 4배 이상 L3, 2~4배 L2, 1~2배 L1, 개선·근거 없음 L0	KV 감소율의 역수는 예산 환산치이지 실측 세션 길이가 아님
D2 응답·비용	비용 절감+SLA 충족 시 TTFT·TPOT 지연 증가 0% 이하 L3, 10% 이내 L2, 초과 L1	절감 없음/SLA 미충족 L0; 필수 지표 누락은 판정 유보

M1 세부 항목과 D2 판정 유보는 과제 기준의 미정의 부분을 보완한 운영 규칙이다. 점수는 코드가 계산하고 원문 근거를 대조한다.

4. 시장성 평가 / DeepSeek-V2 MLA

성장성 높음 (4/6), 채택은 선정 L1·계열 L4, 생태계는 L2다.

M1 성장성

항목	점수	판정 근거
수요 동인	1/2	장문맥 KV 부담을 줄이는 메커니즘은 확인되지만 향후 3년의 기술별 수요 시계열·시장 규모는 확보하지 못했다. [S1]
채택 확대	2/2	V2 이후 V3가 MLA를 유지하고, V3 기반 R1을 AWS가 일반 제공하며 실제 고객 배포를 보고했다. 계열 확산 근거이며 V2 자체의 고객 수는 아니다. [S5] [S8] [S9]
공급·생태계 투자	1/2	vLLM MLA 백엔드와 DeepSeek-V2 구현, FlashMLA는 공급 기반의 존재를 뒷받침한다. 투자 규모의 연속 증가를 증명하지는 않는다. [S3] [S4] [S10]

M2 채택

범위·단계	채택 주체	판정 근거
선정 L1	DeepSeek-AI	V2 논문과 모델 공개를 확인했다. 본 자료 풀만으로 V2의 현재 상용 운영을 확정하지 않는다. [S1]
계열 L4	AWS / Amazon Bedrock 고객	AWS는 R1의 정식 서비스와 수천 고객의 배포를 보고했다. R1→V3→MLA 연결은 모델 원문으로 확인했다. 벤더 자기보고이며 선정 V2의 운영 증거는 아니다. [S5] [S8] [S9]

M3 생태계

항목	확인	판정 근거
프레임워크	Y	vLLM 문서가 MLA 전용 prefill/decode 백엔드와 DeepSeek-V2 MLA 구현을 보여준다. [S3] [S10]
벤더 제품	Y	AWS의 R1 서비스 제공과 원 모델 계보로 MLA 계열 제품을 확인한다. [S5] [S8] [S9]
표준화	N	조사 자료에서 MLA 자체의 산업 표준은 확인하지 못했다.
제3자 연구·도구	N	중복 집계를 피하고 vLLM은 프레임워크로만 계수했다. FlashMLA는 원 개발자의 도구로, 제3자 항목에 포함하지 않았다. [S3] [S4]

원저자 구현 확인 [S1] [S4] · M1은 2026-09-23부터 3년을 바라보는 정성적 전망이다. 4점은 성장을 예측이나 시장 점유율을 뜻하지 않는다. M2의 최고 단계는 채택의 보편성을 뜻하지 않는다.

4. 시장성 평가 / CXL-PNM (PNM-KV / PnG-KV)

성장성 보통 (3/6), 채택은 선정 L1·계열 L3, 생태계는 L2다.

M1 성장성

항목	접수	판정 근거
수요 동인	1/2	선정 논문은 장문맥의 외부 KV 메모리 병목을 다루고, Samsung은 CXL 메모리 풀링을 통한 KV 수용량 확장을 발표했다. 후자는 CXL 계열 자료이며 선정 PNM 구현의 수요 시계열은 아니다. [S2] [S11]
채택 확대	1/2	CXL 메모리 계열 제품 페이지는 확인되지만 선정 PNM-KV/PnG-KV의 상용 고객 사례는 확인되지 않았다. [S6] [S2]
공급·생태계 투자	1/2	CXL 규격·제품과 벤더의 KV 메모리 풀링 발표가 계열 기반을 보여준다. 선정 PNM 구조의 지속 투자 규모와 대량 출하는 별도 검증이 필요하다. [S7] [S6] [S11]

M2 채택

범위·단계	채택 주체	판정 근거
선정 L1	Kim et al. 연구팀	논문은 합성 타이밍·전력 모델로 보정한 사이클 수준 시뮬레이터를 평가에 사용했다. 이 자료만으로 현장 PoC 또는 상용 운영으로 올리지 않는다. [S2]
계열 L3	Samsung Electronics	CMM-D 공식 제품 자료를 확인했다. CXL 메모리 제품이며 해당 논문의 PNM 가속 기능과 동일한 제품이라는 뜻은 아니다. [S6]

M3 생태계

항목	확인	판정 근거
프레임워크	N	논문 자체 런타임은 외부 프레임워크 지원과 구별했다. 선정 구조의 범용 프레임워크 통합은 미확인이다. [S2]
벤더 제품	Y	CMM-D가 CXL 메모리 계열의 제품 근거다. PNM-KV 제품의 증거는 아니다. [S6]
표준화	Y	CXL Consortium의 규격 아카이브가 존재한다. PNM 토큰 선택 알고리즘 자체의 표준은 아니다. [S7]
제3자 연구·도구	N	선정 논문을 자기 자신의 제3자 연구로 집계하지 않았다. 별도 원문을 확보하지 못한 항목은 N으로 남겼다.

원저자 구현 확인 [S2] · 계열 범위를 넓히면 제품·표준의 근거가 늘지만 선정 논문의 상용성은 올라가지 않는다. N은 조사 범위 내 미확인이며 부존재의 증명이 아니다.

5. 도메인 평가 / AI 코딩·업무 에이전트

MLA의 KV 절감은 정량화되지만, 두 기술 모두 코딩 에이전트의 응답 지연·비용은 판정할 근거가 부족하다.

D1 장기 세션 수용성

기술	판정	같은 조건의 근거와 한계
DeepSeek-V2 MLA	L3	DeepSeek-V2 대 DeepSeek 67B의 KV cache 비교. $1/(1-0.933)=14.925$ 배의 동일 KV 예산 환산치이며 실측 세션 길이 배수가 아니다. [S1]
CXL-PNM (PNM-KV / PnG-KV)	L0	최대 1M 문맥 실험은 확인되지만 128K→1M을 동일 하드웨어의 최대 문맥 증가 배수로 간주할 수 없다. GPU-PNM 수가 함께 바뀌며 기존 시스템도 CXL 확장 메모리를 사용한다. [S2]

D2 응답성과 비용

기술	판정	확인되지 않은 지표
DeepSeek-V2 MLA	판정 유보	논문의 최대 처리량 향상을 TTFT·TPOT로 바꾸지 않는다. KV 감소율은 총 운영비 감소율이 아니다. 동일 코딩 에이전트 조건의 지연·비용·SLA 자료가 없다. [S1]
CXL-PNM (PNM-KV / PnG-KV)	판정 유보	평가는 주로 decode 단계와 처리량/달러를 다룬다. 대화형 TTFT를 포함한 동일 SLA 비교가 없으므로 최대 비용 효율 수치만으로 D2를 확정하지 않는다. [S2]

AI 코딩·업무 에이전트에 적용할 때

기술	적용 해석	제약
DeepSeek-V2 MLA	장기 세션당 KV 예산 감소에 연결되는 구조다. 실제 보존 가능한 코드·대화 길이는 모델 문맥 한도, 가중치 메모리, 동시 사용자, 도구 출력량에 함께 제약된다.	MLA 지원 모델과 커널이 필요하다. 일반 모델에 설정 하나로 적용하는 압축 기법이 아니다. 보고된 비교는 모델 구조가 다른 세대 간 비교이며 MLA만의 통제 실험으로 일반화하지 않는다.
CXL-PNM (PNM-KV / PnG-KV)	여러 세션의 KV를 외부 메모리에 수용하고 선택 연산을 메모리 근처에서 처리하는 방향이다. 다수 에이전트의 동시 운용 가능성은 분석적 해석이며 코딩 에이전트 실측은 아니다.	추가 CXL-PNM 하드웨어·드라이버·서빙 경로가 필요하다. 논문은 시뮬레이션 기반 성능 평가이며 요약 작업의 결과를 실제 도구 호출 세션에 직접 전이할 수 없다.

장문맥 수용과 유효한 기억은 다르다. 코드 변경 추적·검색 정확도·도구 호출 성공률은 이 KV 비교만으로 검증되지 않는다.

6. 시사점과 한계

시장 채택과 코딩 에이전트의 응답성·비용은 서로 다른 질문이므로 한 점수로 합치지 않는다.

관점 사이의 차이

쟁점	해석
차이 1	시장 채택 단계가 높더라도 특정 코딩 에이전트의 응답 SLA 충족이 보장되지는 않는다. MLA 계열 서비스 존재와 D2 판정 유보는 모순되지 않는다.
차이 2	외부 메모리 수용량의 확대와 토큰당 KV 압축은 서로 다른 변경 지점을 가진다. 동일 환경 실패 없이 양자의 수치를 직접 순위화하거나 합산하지 않는다.
차이 3	계열의 제품·규격 지원은 연구 기술의 도입 기반이 될 수 있지만, PNM 논문 자체의 상용 운영 증거와 구분해야 한다.

공개 정보와 평가 절차의 한계

구분	한계
한계 1	공개 자료와 벤더 자기보고를 사용했으며 독립적 실측은 수행하지 않았다. 상용 사용량·투자액·향후 3년 성장률은 확인하지 못했다.
한계 2	시장 조사는 MLA 및 PIM/PNM·CXL 기술 계열로 넓혔다. 도메인 수치는 선정 논문 단위를 유지했다. PIM은 포괄 명칭이며 선정 논문의 구체 방식은 PNM이다.
한계 3	M1 세부 3항목과 D2 판정 유보 정책은 미정의 부분을 보완한 운영 규칙이다. M3에서는 동일 근거를 여러 범주에 중복 집계하지 않았다.
한계 4	검색 원문에 근거 ID·페이지·범위를 연결하고, 긍정 주장과 제약을 함께 기록했다. 미확인 자료를 실패나 부존재로 단정하지 않으며 합산 승자를 만들지 않았다.

실행 추적

원문 11개, PDF 실패페이지와 웹 환산페이지 합계 169페이지(웹 3,000자당 1페이지). 임베딩 intfloat/multilingual-e5-small. 청크 ID·원문 해시·검색어·판정 입력은 evaluation.json에 기록했다.

실시간 검색 결과는 원문 검증 후 검토 원장과 대조한다. 일치하지 않는 모델 제안은 보고서에 반영하지 않는다. 재현 모드는 웹검색과 OpenAI 호출을 생략한다.

REFERENCE

[S1] DeepSeek-AI (2024-06-19). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv:2405.04434v5. <https://arxiv.org/abs/2405.04434v5> (확인: 2026-09-23)

[S2] Kim, D. et al. (2025-10-31). Scalable Processing-Near-Memory for 1M-Token LLM Inference: CXL-Enabled KV-Cache Management Beyond GPU Limits. arXiv:2511.00321v1. <https://arxiv.org/abs/2511.00321v1> (확인: 2026-09-23)

[S3] vLLM (발행일 미표기). Attention Backend Feature Support (v0.16.0). vLLM Documentation. https://docs.vllm.ai/en/v0.16.0/design/attention_backends/ (확인: 2026-09-23)

[S4] DeepSeek-AI (발행일 미표기). FlashMLA: Efficient Multi-head Latent Attention Kernels. GitHub. <https://github.com/deepseek-ai/FlashMLA> (확인: 2026-09-23)

[S5] Yun, C. (2025-03-10). DeepSeek-R1 now available as a fully managed serverless model in Amazon Bedrock. AWS News Blog. <https://aws.amazon.com/blogs/aws/deepseek-r1-now-available-as-a-fully-managed-serverless-model-in-amazon-bedrock/> (확인: 2026-09-23)

[S6] Samsung Electronics (발행일 미표기). CMM-D | CXL Memory. Samsung Semiconductor. <https://semiconductor.samsung.com/cxl-memory/cmm-d/> (확인: 2026-09-23)

[S7] Compute Express Link Consortium (발행일 미표기). Past CXL Specifications Landing Page. Compute Express Link. <https://computeexpresslink.org/past-cxl-specifications-landing-page/> (확인: 2026-09-23)

[S8] DeepSeek-AI (발행일 미표기). DeepSeek-R1. GitHub. <https://github.com/deepseek-ai/DeepSeek-R1> (확인: 2026-09-23)

[S9] DeepSeek-AI (2024-12-27). DeepSeek-V3 Technical Report. arXiv:2412.19437v1. <https://arxiv.org/abs/2412.19437v1> (확인: 2026-09-23)

[S10] vLLM (발행일 미표기). `vllm.model_executor.models.deepseek_v2`. vLLM Documentation. https://docs.vllm.ai/en/stable/api/vllm/model_executor/models/deepseek_v2/ (확인: 2026-09-23)

[S11] Samsung Semiconductor (발행일 미표기). Breaking AI Memory Limits with CXL Memory Pooling. Samsung Semiconductor Global. <https://semiconductor.samsung.com/news-events/tech-blog/breaking-ai-memory-limits-with-cxl-memory-pooling/> (확인: 2026-09-23)

arXiv 자료는 프리프린트로 기재했다. 확인되지 않은 학술지·권호·페이지와 발행일은 만들어 넣지 않았다. 웹 문서 확인일은 발행일이 아니다.